

Prediksi Harga Minyak Mentah WTI Menggunakan LSTM Time Series Forecasting

No	Nama	NIM
1	Abdul Kharis	2388010004
2	Siti Malikha	2388010001
3	Muhammad Cevi Maulana Ramadhan	2388010042
4	Muhammad Devani Alghifari	2388010048

Program Studi: Informatika

Universitas: UIN Siber Syekh Nurjati Cirebon

Mata Kuliah: Deep Learning

link Google Colab : https://colab.research.google.com/drive/1AH_MY2Nxg_2nLo5xAtsdsstFN3RjsUVG?usp=sharing

1. MILESTONE 1 — Proposal Kasus & Dataset Scraping

1.1 Kasus yang Dipilih

Judul Kasus: Prediksi Harga Penutupan Minyak Mentah CL=F / WTI (West Texas Intermediate) Berbasis Pendekatan Multivariat Deep Learning.

1.2 Alasan Pemilihan Kasus

Harga minyak mentah merupakan salah satu variabel ekonomi yang paling berpengaruh di dunia. Fluktuasi harga minyak berdampak langsung pada inflasi, nilai tukar, pasar saham, dan pertumbuhan ekonomi global. Jurnal "The Determinants of Crude Oil Prices: Evidence from ARDL and Nonlinear ARDL Approaches" (CESifo Working Paper No. 10050) (Salem et al., 2022) membuktikan secara empiris bahwa harga minyak dipengaruhi oleh berbagai variabel makroekonomi seperti harga emas, indeks dolar AS, harga futures minyak, serta kebijakan ketidakpastian ekonomi (EPU), baik dalam jangka pendek maupun jangka panjang. Hal ini menjadikan masalah prediksi harga minyak sangat kompleks dan sesuai untuk didekati dengan model deep learning berbasis data runtun waktu multivariat.

Selain itu, jurnal "Investigating Factors Influencing Oil Volatility: A GARCH-MIDAS Model Analysis" (Frontiers in Energy Research, 2024) (Le et al., 2024) mengidentifikasi bahwa volatilitas harga minyak dipengaruhi oleh indeks produksi industri (IPI), ketidakpastian kebijakan ekonomi (GEPU), jumlah rig pengeboran global (ADU), serta risiko geopolitik (GPR). Faktor-faktor ini saling berkaitan dan membentuk pola dependensi temporal yang kuat, sehingga model sekuensial seperti LSTM sangat relevan untuk digunakan.

Jurnal ketiga, "Testing the Volatility Spillover between Crude Oil Price and the U.S. Stock Market Returns" (Management Science Letters, 2019) (Kondoz et al., 2019), menunjukkan adanya transmisi volatilitas satu arah dari indeks S&P500 ke harga minyak WTI menggunakan model

BEKK-GARCH. Temuan ini menjadi landasan ilmiah bahwa indeks S&P500 (SP500) merupakan fitur prediktif yang valid dan harus disertakan dalam model prediksi harga minyak.

1.3 Sumber Data

Data diambil secara otomatis menggunakan simulasi browser dengan library selenium dan BeautifulSoup untuk mengekstrak data historis dari Yahoo Finance, yang merupakan sumber data keuangan historis yang terpercaya dan bebas akses. Data yang diambil adalah harga penutupan harian (daily closing price) dari empat instrumen finansial:

Simbol Ticker	Nama Aset	Alasan Pemilihan
CL=F	WTI Crude Oil Futures	Variabel target prediksi
^GSPC	S&P 500 Index	Transmisi volatilitas ke minyak (MSL, 2019)
GC=F	Gold Futures	Korelasi positif dengan WTI (CESifo, 2022)
DX-Y.NYB	US Dollar Index (DXY)	Korelasi negatif dengan WTI (CESifo, 2022)

1.4 Detail Dataset Hasil Scraping

Properti	Nilai
Periode Data (yang diminta)	1 Januari 2000 — 31 Desember 2025
Jumlah Baris (setelah alignment)	Akan ditentukan setelah proses alignment
Jumlah Kolom	4 kolom
Nama Kolom	CL=F_Close
	^GSPC_Close
	GC=F_Close
	DX-Y.NYB_Close
Tipe Data	float64 (semua kolom)
Format Indeks	DatetimeIndex (harian)
File Output	dataset_raw.csv, dataset_clean.csv

Dataset memenuhi syarat minimal 1.000 titik waktu dan bersifat multivariat (lebih dari 2 fitur), sesuai dengan ketentuan Milestone 1.

1.5 Justifikasi Pemilihan Fitur

- WTI (Target): Variabel yang diprediksi. Dipilih karena WTI adalah tolok ukur global harga minyak mentah.

- SP500: Berdasarkan jurnal "Testing the Volatility Spillover..." (MSL, 2019), terdapat spillover volatilitas satu arah dari S&P500 ke harga minyak, sehingga SP500 adalah prediktor yang valid.
- GOLD: Jurnal "The Determinants of Crude Oil Prices" (CESifo, 2022) membuktikan hubungan jangka panjang yang signifikan antara harga emas dan harga minyak WTI, karena keduanya sama-sama dikuotasi dalam dolar AS.
- DXY: Jurnal yang sama membuktikan bahwa pelemahan dolar AS (depresiasi) mendorong kenaikan harga minyak karena meningkatkan permintaan impor minyak dari negara-negara non-dolar.

1.6 Instalasi Library Python

Pada tahap ini dilakukan instalasi beberapa library Python yang digunakan dalam proses scraping dan pengolahan data. Library selenium digunakan untuk otomatisasi browser, webdriver-manager digunakan untuk mengelola ChromeDriver secara otomatis, beautifulsoup4 digunakan untuk parsing HTML, sedangkan pandas digunakan untuk manipulasi dan penyimpanan dataset.

Tahap ini bertujuan untuk memastikan seluruh dependency Python yang dibutuhkan dalam proses scraping tersedia dan dapat digunakan pada environment Google Colab.

1.7 Proses Scraping Data Historis

Pada tahap ini dilakukan proses scraping data historis pasar keuangan dari Yahoo Finance menggunakan kombinasi library Selenium dan BeautifulSoup. Selenium digunakan untuk melakukan simulasi browser secara otomatis, sedangkan BeautifulSoup digunakan untuk melakukan parsing struktur HTML halaman historis Yahoo Finance.

Data yang diambil berupa harga penutupan harian (Close) dari empat instrumen finansial, yaitu WTI Crude Oil Futures (CL=F), S&P500 (^GSPC), Gold Futures (GC=F), dan US Dollar Index (DX-Y.NYB) untuk periode 1 Januari 2000 hingga 31 Desember 2025.

Selain proses scraping, tahap ini juga mencakup konfigurasi browser headless, ekstraksi tabel historis, pembersihan data awal, serta penyimpanan dataset mentah ke dalam file dataset_raw.csv.

2. MILESTONE 2 — Exploratory Data Analysis & Preprocessing

2.1 Pembersihan Data dan Penanganan Missing Values

Dataset mentah hasil scraping (dataset_raw.csv) mengandung ketidakselarasan tanggal akibat perbedaan kalender perdagangan masing-masing instrumen keuangan. Sebelum analisis eksploratif dan pemodelan, dilakukan tahap pembersihan data dengan prosedur berikut:

- Parsing & Indexing: Indeks kolom tanggal dikonversi ke format DatetimeIndex dan diurutkan secara kronologis (sort_index()).
- Penanganan Missing Values:

1. Awalnya terdapat nilai kosong (NaN): WTI (206), SP500 (34), GOLD (215), DXY (5).
 2. Diisi menggunakan forward fill (ffill) untuk propagasi nilai terakhir, dilanjutkan backward fill (bfill) untuk mengisi celah di awal dataset.
- Sinkronisasi Rentang Waktu: Dataset dipotong mulai 2000-08-30 agar seluruh instrumen memiliki periode pengamatan yang identik.

Hasil Akhir Preprocessing Awal:

Properti	Nilai
Jumlah Baris	6.402
Jumlah Kolom	4 (WTI, SP500, GOLD, DXY)
Missing Values	0
Tipe Data	float64
Rentang Waktu	30 Agustus 2000 – 30 Desember 2025

2.2 Analisis Data Eksploratif (Exploratory Data Analysis — EDA)

EDA dilakukan untuk memahami karakteristik statistik, pola temporal, dan hubungan antar variabel sebelum pemodelan. Tujuh analisis utama dilakukan:

- Statistik Deskriptif

Fitur	Mean	Std	Min	Max
WTI	64.52	24.62	-37.63	145.29
SP500	2,286.79	1,466.34	676.53	6,932.05
GOLD	1,246.05	729.54	255.10	4,529.10
DXY	92.51	11.20	71.33	120.90

Catatan: Nilai minimum WTI sebesar -37.63 USD/barel merefleksikan anomali historis pada April 2020 akibat pandemi COVID-19 dan perang harga minyak.

- Visualisasi Tren & Heatmap Korelasi
 1. Tren WTI: Menampilkan siklus boom-bust (2008, 2014–2016, 2020) dan volatilitas ekstrem.
 2. Tren SP500 & GOLD: Menunjukkan tren jangka panjang naik, dengan dip tajam saat krisis makroekonomi.
 3. Tren DXY: Berfluktuasi terbalik secara teoritis terhadap komoditas.
 4. Matriks Korelasi Pearson:

Hubungan	Korelasi	Interpretasi
WTI vs DXY	-0.58	Negatif sedang (penguatan dolar tekan harga minyak)
WTI vs GOLD	+0.40	Positif sedang (terdorong inflasi & ketidakpastian)
WTI vs SP500	+0.16	Positif lemah (keterkaitan permintaan energi & aktivitas ekonomi)

Hasil EDA selaras dengan literatur CESifo (2022) dan MSL (2019), mengonfirmasi bahwa dataset memiliki pola dependensi yang realistis untuk pemodelan multivariat.

2.3 Rekayasa Fitur — Lag Features (Feature Engineering)

Untuk menangkap dependensi temporal secara eksplisit, dilakukan rekayasa fitur menggunakan lag pada variabel target WTI.

Fitur	Makna	Justifikasi
WTI_lag_1	Harga 1 hari sebelumnya (t-1)	Menangkap inersia pasar & pola autoregresif jangka sangat pendek
WTI_lag_3	Harga 3 hari sebelumnya (t-3)	Merepresentasikan pola mingguan awal perdagangan
WTI_lag_7	Harga 7 hari sebelumnya (t-7)	Menangkap siklus mingguan penuh (sinkron dengan rilis data stok EIA)

Implementasi: Menggunakan `df['WTI'].shift(k)` diikuti `dropna()` untuk menghapus 7 baris awal yang menghasilkan NaN.

- Hasil Dataset: 6.395 baris
- fitur (WTI, SP500, GOLD, DXY, WTI_lag_1, WTI_lag_3, WTI_lag_7).

2.4 Definisi Variabel Target dan Fitur

Sebelum masuk ke tahap normalisasi, variabel dipisahkan secara eksplisit:

- Target (y): Kolom WTI (harga yang akan diprediksi).

- Fitur Input (X): Seluruh DataFrame hasil rekayasa fitur (7 kolom).

Prinsip Anti-Data Leakage: Normalisasi belum dilakukan secara global untuk keperluan pelatihan model. Scaler hanya akan di-fit pada data training, lalu parameter transformasinya diaplikasikan ke data testing. Normalisasi pada tahap ini dilakukan murni untuk dokumentasi eksplorasi dataset.

Dataset disimpan sebagai:

1. dataset_preprocessed_features.csv
2. dataset_preprocessed_target.csv

2.5 Scaling / Normalisasi Data

Variabel dalam dataset memiliki skala yang sangat berbeda (misal: SP500 $\approx$ ribuan, DXY $\approx$ puluhan). Untuk menstabilkan konvergensi gradient descent pada LSTM, dilakukan normalisasi menggunakan MinMaxScaler ke rentang [0, 1].

Rumus Transformasi:

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Pemilihan MinMaxScaler:

1. Cocok untuk data runtun waktu karena mempertahankan bentuk distribusi asli.
2. Kompatibel dengan arsitektur LSTM yang sensitif terhadap skala input.
3. Output ternormalisasi mempercepat konvergensi dan mencegah dominasi fitur berskala besar.

Hasil: Seluruh 6.395 baris dan 7 fitur berhasil ditransformasi ke rentang 0.00 – 1.00 tanpa kehilangan informasi temporal. File disimpan sebagai dataset_normalized.csv sebagai deliverable Milestone 2.

Kondo, M., Bora, I., Kirikkaleli, D., & Athari, S. A. (2019). Testing the volatility spillover between crude oil price and the U.S. stock market returns. *Management Science Letters*, 9(8), 1221–1230. <https://doi.org/10.5267/j.msl.2019.4.019>

Le, Y., Wen, J., Wu, Y., Liu, J., & Zhu, Y. (2024). Investigating factors influencing oil volatility: a GARCH-MIDAS model analysis. *Frontiers in Energy Research*, 12. <https://doi.org/10.3389/fenrg.2024.1392905>

Salem, L. Ben, Nouira, R., Jeguirim, K., & Rault, C. (2022). *The Determinants of Crude Oil Prices: Evidence from ARDL and Nonlinear ARDL Approaches*. www.RePEc.org