1. AI yang memungkinkan komputer memahami, memproses, hasilkan bahasa manusia.

- Tujuan: Mengubah data tidak terstruktur (teks mentah) menjadi data terstruktur (Intent, Sentiment, Entity).
- Tantangan (khususnya Bahasa Indonesia): Ambiguitas makna (contoh: "bisa" = racun/mampu), slang ("ga", "gk", "bgt"), singkatan, dan morfologi kompleks (imbuhan).

4 Era NLP

Era	Rentang	Pendekatan Utama	Karakteristik / Limitasi
Era 1: Dawn	1950-1969	Dictionary Look-up	Terjemahan kata-per-kata (kaku). Contoh: Georgetown-IBM Demo (1954).
Era 2: Rule-Based	1970-1992	Hand-crafted Rules	Dibuat ahli bahasa/linguis. Rapuh (*brittle*) jika kena bahasa gaul, mahal, dan tidak *scalable*. Contoh: SHRDLU.
Era 3: Statistical	1993-2012	Machine Learning, N-Grams	Berbasis frekuensi/probabilitas. Manusia memberi label data. Masalah: *Sparsity*. (Algoritma: HMM, SVM awal).
Era 4: Deep Learning	2013-Skrg	Word Embeddings, LLMs	Vektor padat (Word2Vec), Transformer (*Self-supervised*). Komputer memahami semantik (Contoh: King - Man + Woman ≈ Queen).

2. PIPELINE PREPROCESSING TEKS

Mengubah teks mentah menjadi format bersih untuk menekan *noise* dan mengurangi dimensi data.

A. Tokenisasi Memecah teks menjadi unit kecil (*token*).

- Word Tokenization: Pemecahan per kata (Hati-hati dengan tanda baca, NLTK memisahkannya).
- Sentence Tokenization: Pemecahan per kalimat (Tantangan: titik pada singkatan Dr. atau URL/desimal).
- Gunakan TweetTokenizer untuk data media sosial (menjaga keutuhan emoticon :), hashtag #, dan mention @univ).

B. Normalisasi (Cleaning)

- Case Folding: Mengubah semua huruf menjadi kecil (.lower()).
- Kapan JANGAN dilakukan: Pada task NER (kapitalisasi adalah fitur penanda nama/organisasi) dan Analisis Sentimen (huruf kapital menandakan intensitas/emosi, misal: BAGUS!).
- Cleaning Ekstra: Gunakan Regex untuk hapus angka (r'\d+'), URL (r'http\S+'), Punctuation (r'[^\w\s]'), email, dan spasi berlebih.

C. Stopword Removal hapus kata frekuensi tinggi namun minim informasi (*dan, yang, di, ke*).

- Keuntungan: Mengurangi dimensi fitur secara drastis (hingga 40%) dan mempercepat komputasi.
- Peringatan untuk Sentimen: JANGAN HAPUS kata negasi (*tidak, bukan, kurang*) dan kata intensitas (*sangat, terlalu*). Gunakan *custom stopwords*.

D. Stemming vs Lemmatization (Mencari Bentuk Dasar)

Fitur	Stemming	Lemmatization
Metode	Potong afiks/imbuhan (kasar)	Analisis Linguistik (butuh kamus & POS tag)
Kecepatan	Sangat Cepat	Lebih Lambat
Hasil	Kadang bukan kata valid (pelajaran $\rightarrow$ ajar)	Selalu kata valid (better $\rightarrow$ good)
Library	Sastrawi (Indonesia), Porter (Inggris)	WordNetLemmatizer NLTK (Inggris)
Catatan: Lemmatization tanpa POS tag defaultnya akan menganggap kata sebagai *noun* (kata benda).		

3. FEATURE ENGINEERING TRADISIONAL ubah teks menjadi vektor angka agar bisa dipahami algoritma ML.

1. Integer Encoding

Memberi ID numerik unik tiap kata.

- ❌ Kelemahan Fatal: Model salah mengira ada urutan/hierarki matematis (misal: ID 3 dianggap lebih besar/bernilai dari ID 1).

2. One-Hot Encoding

Vektor biner 0 dan 1 (hanya satu posisi yang menyala).

- ❌ Kelemahan: Sangat boros memori (*High Dimensionality* & *Sparsity*: 99.9% isinya angka 0), tidak menangkap kedekatan makna (Dot product "kucing" dan "anjing" = 0), dan tidak bisa menangani *Out-of-Vocabulary* (OOV).

3. Bag of Words (BoW)

Merepresentasikan jumlah kemunculan frekuensi tiap kata di dalam dokumen.

- ✅ Kelebihan: Mudah diimplementasikan & cukup *powerful*.
- ❌ Kekurangan: Hilang informasi urutan kata dan grammar ("kucing makan ikan" dianggap sama persis dengan "ikan makan kucing").

4. TF-IDF (Term Frequency - Inverse Document Frequency)

Memberi bobot tinggi pada kata yang sering muncul di 1 dokumen, tapi jarang di dokumen lain.

- TF (Term Frequency): Seberapa sering kata muncul di suatu dokumen.
- IDF (Inverse Document Freq): Seberapa langka kata itu di seluruh koleksi.
- Rumus: $TF \times \left(\log\left(\frac{N}{df(t)+1}\right) + 1\right)$
- Parameter Sklearn: max_features (batasi vocab), ngram_range ((1,2) tangkap unigram & bigram).

5. Cosine Similarity

Mengukur sudut (θ) antar dua vektor dokumen. Tidak terpengaruh besaran/panjang dokumen.

- $\cos(\theta) = 1.0$ (Identik / Sudut 0°)
- $\cos(\theta) = 0.0$ (Sama sekali berbeda / Orthogonal / Sudut 90°)
- $\cos(\theta) = -1.0$ (Berlawanan arah / Sudut 180°)
- Rumus: $\cos(\theta) = \frac{A \cdot B}{||A|| \times ||B||}$

4. KLASIFIKASI TEKS DENGAN ML

Algoritma Klasifikasi

1. Naive Bayes: Pendekatan Probabilistik berdasar Teorema Bayes. Sangat cepat untuk *baseline*.
   - Asumsi Naif: Setiap kata muncul secara independen (tidak mempedulikan grammar).
   - Rumus: $P(c|d) = \frac{P(d|c) \times P(c)}{P(d)}$
   - Log-Sum Trick: Mencegah *numerical underflow* (karena mengalikan banyak probabilitas desimal).
   - Laplace Smoothing: Menambah nilai $a = 1$ agar probabilitas kata baru (OOV) tidak menjadi 0.
2. Logistic Regression: Menggunakan fungsi Sigmoid untuk mengubah kombinasi linear menjadi probabilitas (0-1). Ambang batas (*threshold*) standar = 0.5. Evaluasi menggunakan *Binary Cross-Entropy Loss*.
3. SVM (Support Vector Machines): Mencari batas pemisah (*hyperplane*) terbaik antar kelas. Sangat efektif untuk data teks karena sangat baik menangani dimensi tinggi (*High Dimensionality*) dan data kosong (*Sparsity*).

Data Leakage (Kebocoran Data)

- ❌ PANTANGAN: Jangan mem-fit TF-IDF menggunakan seluruh data sebelum memisahkan *train/test set*.
- ✅ SOLUSI: Gunakan .fit_transform() HANYA pada data *Train*, dan .transform() pada data *Test*.

5. EVALUASI MODEL & ERROR ANALYSIS (ROBUST EVALUATION)

Akurasi tunggal sering kali menyesatkan, terutama pada data yang tidak seimbang (*Imbalanced Data*).

A. K-Fold Cross Validation

Membagi data menjadi K bagian (fold). Latih pada $K-1$, uji pada sisa 1. Lakukan bergantian hingga tiap fold diuji 1x.

- Laporkan selalu Mean (Rata-rata) dan Standard Deviation (SD).
- SD tinggi (> 5%) menandakan model memiliki *High Variance* (tidak stabil terhadap perubahan data latih).
- Jangan lakukan *tuning hyperparameter* di data uji, gunakan *Nested CV* atau *Validation Set* terpisah untuk menghindari *Selection Bias*.

B. Confusion Matrix & Metrik Utama

Jika dari 1000 email ada 950 Normal dan 50 Spam, model yang selalu menebak "Normal" akan mendapat Akurasi 95% (*The Accuracy Paradox*).

- Accuracy: $\frac{TP+TN}{TP+TN+FP+FN}$ (Menyesatkan di *imbalanced data*!).
- Precision (Presisi): $\frac{TP}{TP+FP}$ (Fokus meminimalkan alarm palsu / *False Positives*).
- Recall (Sensitivitas): $\frac{TP}{TP+FN}$ (Fokus meminimalkan yang lolos dari deteksi / *False Negatives*).
- F1-Score: Rata-rata harmonik Precision & Recall $\rightarrow$ $2 \times \frac{Precision \times Recall}{Precision + Recall}$ (Gunakan ini sebagai patokan utama untuk data *imbalance*).

C. Error Analysis (Taksonomi Pareto)

Lakukan inspeksi manual pada sampel prediksi yang salah. Penyebab utama kegagalan model NLP:

1. Syntactic Ambiguity (34%): Parser gagal memahami struktur ambigu ("Melihat pria dengan teleskop").
2. Semantic Drift (28%): Makna ganda/bergeser (Kata "Viral" di bidang medis vs media sosial).
3. Out-of-Vocabulary (19%): Kata baru, typo, neologisme.
4. Negation Scope (11%): Gagal memproses negasi ganda ("Tidak buruk sama sekali").

D. CheckList Framework (Pengujian Behavioral)

Menguji model layaknya *software*, bukan sekadar melihat metrik akhir.

1. MFT (Minimum Functionality Test): Uji kapabilitas dasar (Contoh: "Film ini bagus" harus diprediksi positif. Jika gagal, model belum layak pakai).
2. INV (Invariance Test): Mengganti elemen tanpa mengubah makna (Contoh: ganti nama dari "Budi" ke "Fatimah"). Prediksi harus TETAP SAMA. Berguna untuk mendeteksi Bias/Rasisme/Sexisme.
3. DIR (Directional Expectation Test): Menambahkan kata yang memodifikasi makna dengan cara yang jelas (Contoh: tambah kata "sangat"). Probabilitas prediksi harus BERUBAH searah dengan modifikasi.

Naive Bayes

Date

data training 16 dokumen 2 kelas

kelas positif 3 dokumen

D1 : Film bagus

D2 : bagus sekali menarik

D3 : Cerita menarik bagus

kelas negatif (3 dokumen)

D4 : Film membosankan

D5 : jelek sekali

D6 : Film cerita jelek membosankan

- Tahap 1 - Prior Probability

$P(positif) = \frac{3}{6} = 0.5$ $\quad$ $P(negatif) = \frac{3}{6} = 0.5$

- Tahap 2 bangun vocabulary

cari kata unik dari dokumen

#	kata		+	-
1	Film		1	2
2	bagus	[V] = 7	3	0
3	sekali		1	1
4	menarik		2	0
5	cerita		1	1
6	jelek		0	2
7	membosankan		0	2
			8	8

- Tahap 3 hitung frekuensi kata perkelas

positif

D1 : Film (1), bagus (1)

D2 : bagus (1), sekali (1), menarik (1)

D3 : cerita (1), menarik (1), bagus (1)

negatif

D4 : Film (1), membosankan (1)

D5 : jelek (1), sekali (1)

D6 : Film (1), cerita (1), jelek (1), membosankan (1)

Tahap 4 Laplace smoothing

$\phi(w|c) = \frac{count(w,c) + 1}{total\ words + |V|}$

Penyebut : 8+7 = 15

kata	count (+)	P(w/pos)	count (-)	P(w/neg)
Film	1	(1+1)/15 = 2/15	2	(2+1)/15 = 3/15
bagus	3	(3+1)/15 = 4/15	0	(0+1)/15 = 1/15
sekali	1	(1+1)/15 = 1/15	1	(1+1)/15 = 2/15
menarik	2	(2+1)/15 = 3/15	0	(0+1)/15 = 1/15
cerita	1	(1+1)/15 = 2/15	1	(1+1)/15 = 1/15
membosankan	0	(0+1)/15 = 1/15	2	(2+1)/15 = 2/15
jelek	0	(0+1)/15 = 1/15	2	(2+1)/15 = 2/15
		13/15		15/15

Tahap 5 - klasifikasi dokumen baru

Test dokumen : "Film menarik"

$\hat{c} = \arg\max [\log P(c) + \sum \log P(w|c)]$

Skor + : $\ln(0.5) + \log(\frac{3}{15}) + \log(\frac{3}{15})$

$= 0.693 + (-2.015) + (-1.609)$

$= -4.317$

Skor - : $\ln(0.5) + \ln(3/15) + \ln(1/15)$

$= -0.693 + (-1.609) + (-2.78)$

$= -5.010$

$-4.317 > -5.010 \rightarrow$ positif

1. input & label

Film ini bagus tp membosankan

label (y) : 0 → neg (jelek)

2. Preprocesing → fitur vector bow

1 vocab sederhana

Token	ada?
bagus	1
jelek	1

$x = [x_1, x_2] = [1, 1]$

3. Inisialisasi param

data training

- hitung Prior $(P(c))$
- bangun vocab $|V|$
- hitung word count per kelas
- laplace smoothing → $P(w|c)$ ← solusi zero
- Text dot

$w_1 = (0,8)$ (bagus → pos)

$w_2 = (0,6)$ (jelek → neg)

$b = 0,1$

4. $z = w_1 x_1 + w_2 x_2 + b$

$(0,8)(1) + (-0,6)(1) + 0,1$

$= 0.3$

5. Sigmoid prob y

$\hat{y} = \sigma(z) = \frac{1}{1+e^{-z}}$

$\hat{y} = \frac{1}{1+e^{-0,3}} = \frac{1}{1+0,7408} = \frac{1}{1,7408} = 0,5744$

$\hat{y} = \frac{1}{1+e^{-0,3}} = \frac{1}{1+0,7408} = \frac{1}{1,7408} = 0,5744$

maka pred → 57% +

6. Binary Cross Entropy loss

$\mathcal{L} = -[y \log(\hat{y}) + (1-y) \log(1-\hat{y})]$

$y = 0$

$\mathcal{L} = -[0 \log(0,5744) + 1 \log(1-0,5744)]$

$\mathcal{L} = -\log(0,4236) \approx -(-0,8527)$

$\mathcal{L} \approx 0,8527$

7. loss

$\hat{y}$ pos	y label	loss
0,5744	0 (neg)	0,8527 - high
jika $\hat{y} = 0,1$	0	0,105 → 0 kecil, pred ✓
jika $\hat{y} = 0,9$	0	2,303 → loss high

Era 1 The dawn 1950-1959 Lookup dictionary Pdf E-kamus tidak paham glasnas dan ~~bangung~~ hanya kata

Era 2 rule based 1970-1990 hand crafted rules Ahli gramar manual HCF Lalu lemah, sarik, mahal kamus ifsegmentasi.

Era 3 stats rev 1993-2013 Let data speak → Probabilitas N-grams HMM, SVM Sparsity cuma kata (ada/tidak) butuh label manual SMOTE

Era 4 DL 2013 - now Word embedding representasi terdistribusi; arsitektur Sarat GPU Word2vec RNN, LSTM konsisten Boya besar sumber besar resiko fiks Chat GPT klasifikasi by tagging & word ~~tanpa~~ pada kata

George Boum - IBM 1959

DP : bangun noise, konsisten format, dimensi, + kualitas, RN pandangan = kosakata, ~~tanpa~~ ~~kosakata~~ Menangani = kamus, a kata baru : Ve dasar, FP

Tokenisasi : mecah, CF, lower, ganti, w5 FGF normalisasi : lowcaf ; stopword : hapus informasi, stemming / lemmatization

Text 3PT 10-100M parameter

Basic 100-300d 768 100d 5-12 - 800 5-12 100M-10B

apa = cekan bow, tf-idf text → nuansa

Jika St